

PARTE II

# Data Warehouse Dimensional e Processo ETL

Decisões técnicas de integração de 4 sistemas transacionais em um esquema estrela único — Sistema de Locação de Veículos

---

Banco de Dados / Big Data — Instituto de Computação, UFRJ

Tadeu Belfort Neto • Vicente Alves • João Pedro de Lacerda

# O problema: o mesmo domínio, modelado de quatro formas incompatíveis

Quatro grupos projetaram, de forma independente, o banco transacional de uma locadora. Cada um decidiu sozinho sobre normalização, granularidade e dialeto SQL. Reconciliar essas divergências a cada consulta seria inviável — o ETL resolve isso uma única vez, na carga.

1

**Fontes heterogêneas** PF/PJ por discriminador, por herança ou modelo unificado; dialetos diferentes.

2

**Objetivo analítico central** A matriz de percentuais de movimentação de veículos entre os pátios da rede.

3

**Entrega ao usuário** Um modelo estável e conformado, isolado da complexidade das origens.

## A justificativa de um DW


### Consolidar

dados de múltiplos sistemas em um repositório analítico único

Resultado: relatórios gerenciais confiáveis e a matriz de movimentação entre pátios, a partir de uma base coerente.

# ETL em camadas: staging → conformance → estrela

Cada camada tem uma responsabilidade única e é executada na ordem das pastas. O dado bruto nunca é exposto ao usuário de negócio.



## Full load periódico

Carga completa diária às 00h — sem CDC.

## Idempotente

Cada etapa recria suas tabelas (DROP + CREATE).

## Rastreável

sistema\_origem em cada linha; reconciliação no fim.

# Quatro fontes escolhidas para cobrir todo o espectro de modelagem

A diversidade foi proposital: cada fonte exercita um desafio de conformação diferente, validando a robustez das transformações.

| Grupo do projeto                                                                                                                                               | Grupo 2                                                                                                                                                         | Grupo 4                                                                                                                             | Grupo 5                                                                                                           |
|----------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|
| <b>REFERÊNCIA DE CONFORMAÇÃO</b><br><br>Expressa o par origem–destino de pátios de forma explícita (movimentacao_patio) e separa datas previstas × realizadas. | <b>O MAIS RICO E NORMALIZADO</b><br><br>Devolução como entidade própria, caução com estado, specs constantes × variáveis e documentos de clientes estrangeiros. | <b>FORTEMENTE NORMALIZADO</b><br><br>Endereço como entidade compartilhada, herança explícita PF/PJ e vaga modelada individualmente. | <b>O MAIS ENXUTO</b><br><br>Endereço e cobrança como texto livre; acessórios representados por colunas booleanas. |

# Carga completa (full load) para uma staging raw

## 1 Full load, não incremental

Volume reduzido e contexto acadêmico justificam recriar tudo. Elimina rastrear marcas de alteração (CDC) em 4 esquemas heterogêneos.

## 2 Agendada para 00h00

Início da madrugada — menor atividade dos sistemas transacionais.

## 3 Um script por fonte

Fontes diferem em dialeto SQL e estrutura; cada extração é específica.

## 4 Camada raw, sem modificação

Valores originais preservados para auditoria e reprocessamento. Cada extração registra volume de linhas e instante de execução.

### o que entra na staging

```
stg.cliente
stg.veiculo
stg.locacao
stg.reserva
stg.movimentacao_patio
stg.patio · stg.cobranca
```

---

Cada linha carrega grupo\_fonte + src\_id — a chave natural que evita colisões entre as quatro origens.

# Conformance: onde as divergências são resolvidas de vez

O esquema do próprio grupo foi adotado como referência de conformação — já expressa o par origem-destino de pátios e mantém a distinção previsto × realizado com integridade temporal.

## Movimentação entre pátios

A transformação mais crítica — sustenta a matriz de movimentação.

## Conformação de clientes

Três representações de cliente achatadas a um grão comum.

## Tipos, datas e domínios


Booleanos, timestamps e categóricos unificados entre dialetos.

## Geografia e devolução

Cidade/UF extraídas dos endereços; devolução reincorporada à locação.

# Reconstruir o par origem → destino dos pátios

A matriz de movimentação exige, para cada locação, de qual pátio o veículo saiu e em qual foi devolvido. Cada fonte entrega isso de um jeito.



Documentar e tratar essa indireção foi o ponto de maior esforço — e o que mais reforçou o valor de uma staging intermediária.

# Três representações de cliente, um único grão

As fontes representam o cliente de formas distintas. A transformação converge todas ao nível comum de granularidade, identificando cada cliente por uma chave substituta (surrogate key).



Projeto + Grupo 5

## Discriminador PF/PJ

Um campo de tipo distingue pessoa física e jurídica.



Grupo 4

## Herança em tabelas

Pessoa Física e Pessoa Jurídica em tabelas separadas — herança achatada na conformação.



Grupo 2

## Modelo unificado

Tabela única com suporte a documentos de clientes estrangeiros.



**dw.dim\_cliente** — tipo PF/PJ derivado da fonte, atributos sem correspondência descartados, surrogate key + sistema\_origem garantindo unicidade entre grupos.



# Unificar dialetos: PostgreSQL, MySQL e ANSI genérico

| Aspecto           | Como aparece nas fontes                              | Após conformação        |
|-------------------|------------------------------------------------------|-------------------------|
| Booleanos         | BOOLEAN · TINYINT(1) 0/1                             | BOOLEAN único           |
| Carimbos de tempo | TIMESTAMP · DATETIME · DATE                          | Formato de data único   |
| Catégoricos       | Domínios divergentes por fonte                       | Domínios harmonizados   |
| Geografia         | Só cidade (projeto) · endereço norm alizado (G2, G4) | Cidade + UF extraídas   |
| Devolução         | Entidade própria (G2) · cam po na locação            | Reincorporada à locação |

Resultado: toda fonte passa a falar a mesma língua antes de entrar no esquema estrela — pré-requisito para somar métricas com segurança.

# Dimensões primeiro, fatos depois — e reconciliação ao final

- 1 Ordem ditada pelas dependências** Carregam-se as dimensões e só então o fato, garantindo que toda FK do fato encontre a dimensão já presente.
- 2 Surrogate keys geradas na carga** As chaves substitutas nascem nas dimensões e são referenciadas pelo fato.
- 3 Recriação a cada execução** Por ser carga completa, o conteúdo é refeito — elimina duplicação. 01\_create\_dw.sql é destrutivo (DROP SCHEMA CASCADE).
- 4 Reconciliação final** Compara a contagem de linhas da staging com a do DW ao término da carga.

## ordem de carga

din\_tem po



din\_cliente



din\_veiculo




din\_patio + demais din s



fato\_locacao + fatos

# Esquema estrela com a dimensão de pátio em dois papéis

Grão do fato: uma locação concluída. A dimensão de pátio é referenciada duas vezes — origem e destino — viabilizando a matriz de transição sem duplicar dados (role-playing dimension).



**Métricas aditivas** (valor, dias, km) somáveis por qualquer dimensão · **dimensão degenerada** (id da locação na origem) · **ramo snowflake** em dim\_veiculo → grupo/empresa

# Cada decisão, um conceito da disciplina

## Grão do fato

Uma locação concluída — define o nível de detalhe e o que pode ser perguntado.

## Métricas aditivas

valor, dias e km somáveis em todas as dimensões.

## Dimensão degenerada

Id da locação na origem mora no próprio fato.

## Chave natural composta

(grupo\_fonte, src\_id) evita colisão entre as 4 origens.

## Role-playing dimension

dim\_patio reaproveitada como origem e destino: a base da matriz de movimentação.

## SCD Tipo 1

Dimensões refletem o estado atual; sem versionamento histórico.

## Snowflake pontual

dim\_veiculo normaliza grupo e empresa — estrela com um ramo.

## Pipeline idempotente

Funções IMMUTABLE + recriação de tabelas = cargas determinísticas e testáveis.

# O ETL é o que torna possível um modelo analítico coerente

## Heterogeneidade de dialetos

PostgreSQL × MySQL × ANSI exigiu cuidado constante com booleanos e timestamps.

## Reconstrução indireta

A junção em 3 saltos do Grupo 2 foi o maior desafio e reforçou o valor da staging.

## Granularidades distintas

Decidir quais atributos de cliente e endereço preservar para um grão comum.

## Atributos sem correspondência

Caução, extensão de reserva e specs de combustível ficaram fora do modelo.

## Conclusão

Diante de quatro sistemas que modelam o mesmo domínio de formas incompatíveis, só um ETL bem definido consolida tudo num esquema estrela coerente. O resultado entrega métricas estáveis e sustenta a matriz de movimentação entre pátios — isolando o usuário final da complexidade das origens.