

Projeto de Data Warehouse — Sistema de Locação de Veículos

Parte II — Documento 1: Relatório do processo ETL e do modelo dimensional

Grupo: Tadeu Belfort Neto (DRE 119034813), Vicente Alves (DRE 120044148), João Pedro de Lacerda (DRE 116076670)

1. Introdução

Este documento apresenta comentários sobre o desenvolvimento do processo de Extração, Transformação e Carga (ETL) e do modelo dimensional do Data Warehouse (DW) projetado para um sistema de locação de veículos.

O objetivo central da solução de DW, neste projeto, é consolidar dados oriundos de múltiplos sistemas transacionais, projetados de forma independente por diferentes grupos, em um repositório analítico unificado, capaz de sustentar relatórios gerenciais e, em especial, a construção da matriz de percentuais de movimentação de veículos entre os pátios da rede.

O que motivou a adoção de um DW, principalmente, já aparece na origem dos dados: cada sistema fonte modelou o mesmo domínio de negócio segundo suas próprias decisões de normalização, granularidade e dialeto SQL. Reconciliar essas divergências diretamente em tempo de consulta seria complexo e pouco confiável. O processo ETL resolve essas incompatibilidades previamente, durante a carga, entregando ao usuário analítico um modelo estável, padronizado e conformado.

2. Fontes de dados escolhidas e justificativa

Além do esquema relacional do próprio grupo, projetado em PostgreSQL, foram selecionados os esquemas de outros três grupos da turma como fontes adicionais do ETL. A escolha priorizou a diversidade de decisões de modelagem, de modo que a integração exercitasse os principais desafios de conformação.

Internamente, cada registro extraído recebe um identificador de procedência (`grupo_fonte`) e uma chave natural conformada no padrão `grupo_fonte-src_id`, o que permite unir fontes distintas sem colisão de chaves.

- Grupo 2: o esquema mais rico e normalizado, com devolução como entidade própria, caução com estado, separação entre especificações constantes e variáveis do veículo e suporte a documentos de clientes estrangeiros.
- Grupo 4: esquema fortemente normalizado, com endereço como entidade compartilhada, herança explícita de cliente em pessoa física e jurídica, e vaga modelada individualmente.
- Grupo 5: o esquema mais enxuto, com endereço e dados de cobrança como campos de texto livre e acessórios representados por colunas booleanas.

2.1 Quadro comparativo das fontes

Eixo de modelagem	Grupo do projeto	Grupo 2	Grupo 4	Grupo 5
SGBD / dialeto	PostgreSQL	MySQL	MySQL	SQL genérico
Endereço	Cidade no cliente	Entidade	Entidade	Campo

Eixo de modelagem	Grupo do projeto	Grupo 2	Grupo 4	Grupo 5
		normalizada	normalizada.	textual
Cliente PF/PJ	Discriminador com CHECK	Model. Unificado + doc. estrangeiro	Herança em Três tabelas	Discriminador
Devolução	Embutida na locação	Entidade separada	Embutida na locação	Embutida na locação
Movimentação entre pátios	Tabela dedicada e pátios na locação	Recuperada por junções	Campos na locação	Campos na locação
Previsto × realizado	Explícito com restrições	Parcial	Sim	Sim

3. Processo de Extração ETL

A extração alimenta uma área de staging, implementada no esquema *stg*, e adota estratégias diferentes conforme a natureza da tabela.

As tabelas de cadastro mais estáveis: cliente, condutor, grupo de veículo, veículo e pátio são extraídas por carga completa. Já as tabelas de movimento: reserva, locação, cobrança e movimentação entre pátios são tratadas com lógica incremental, por meio de uma janela temporal baseada na última execução bem-sucedida registrada em *stg.log_extracao*.

Para cada fonte foi construído um script de extração específico, pois os esquemas diferem tanto no dialeto SQL quanto na estrutura das tabelas. Os dados entram primeiro em uma camada *raw* da staging, preservando os valores originais para auditoria e reprocessamento.

Cada execução registra, em *stg.log_extracao*, o grupo de origem, a tabela, o volume de linhas e o instante da extração, o que permite reconciliar posteriormente o que foi efetivamente carregado por fonte.

4. Processo de Transformação ETL

A transformação é a etapa em que as divergências de modelagem entre as fontes são efetivamente resolvidas. Adotou-se o esquema do próprio grupo como principal referência de conformação, decisão adequada por dois motivos: ele expressa o par origem–destino de pátios de forma explícita e mantém a distinção entre datas previstas e realizadas com restrições de integridade temporal.

A partir da staging *raw*, os dados passam por uma camada conformada, responsável por padronizar nomes, tipos, domínios, chaves e granularidades antes da carga no DW.

4.1 Conformação da movimentação entre pátios

Esta foi a transformação mais crítica, por sustentar diretamente a matriz de movimentação exigida nos relatórios e a análise por cadeia de Markov.

No esquema do próprio grupo, a movimentação é registrada de forma dedicada. Nos Grupos 4 e 5, o par origem–destino é obtido diretamente dos campos de pátio de retirada e devolução da locação. Já no Grupo 2, o destino real só é recuperável por uma junção indireta entre locação, devolução, vaga e pátio, pois a locação registra apenas o pátio de retirada.

As movimentações conformadas são consolidadas em `stg.conf_movimentacao_patio`, com veículo, pátio de origem, pátio de destino e data da movimentação.

4.2 Conformação de clientes e condutores

As fontes representam o cliente de três formas: discriminador PF/PJ no esquema do projeto e no Grupo 5, herança em tabelas separadas no Grupo 4 e modelo unificado com documento estrangeiro no Grupo 2.

A transformação achata a herança e converte todas as representações a uma estrutura comum, gerando uma chave natural conformada por cliente e por condutor.

Quando o nome de origem vem vazio ou ausente, a transformação registra a ocorrência como dado incompleto, permitindo rastreabilidade da qualidade da informação no DW.

4.3 Padronização de tipos, datas e domínios

Por envolver fontes em PostgreSQL, MySQL e SQL genérico, a transformação unifica as representações de tipos. Valores booleanos podem aparecer como `BOOLEAN` em uma fonte e como `TINYINT(1)` em outra. Da mesma forma, campos temporais aparecem como `TIMESTAMP`, `DATETIME` ou `DATE`.

Todas as datas foram padronizadas para um formato único, e os campos categóricos tiveram seus domínios harmonizados.

Medidas derivadas, como quantidade de dias e quilometragem percorrida, são calculadas já na camada conformada, com regras de proteção para evitar valores negativos. Assim, a carga no DW consome medidas previamente tratadas, evitando recálculos divergentes nas consultas analíticas.

4.4 Conformação geográfica e da devolução

Como o esquema do grupo guarda a cidade diretamente no cliente, a transformação extrai a cidade e, quando disponível, a UF dos endereços normalizados dos Grupos 2 e 4.

No caso do Grupo 2, a entidade de devolução é reincorporada à linha analítica da locação. Com isso, todas as fontes passam a produzir um registro de locação contendo as informações necessárias de retirada e devolução, mesmo que essas informações estejam distribuídas em tabelas diferentes no sistema de origem.

5. Carga ETL no Data Warehouse

A carga obedece à ordem ditada pelas dependências do modelo: primeiro as dimensões, depois as três tabelas de fatos.

Antes da carga de cada fato, executam-se validações bloqueantes de orfandade. Caso alguma linha referencie uma dimensão obrigatória ausente, a carga é abortada com erro, em vez de inserir o fato silenciosamente.

As chaves substitutas são geradas na carga das dimensões e resolvidas nos fatos a partir das chaves naturais conformadas.

Todas as dimensões são tratadas como SCD Tipo 1, com sobrescrita via `ON CONFLICT DO UPDATE`, sem manutenção de histórico. Assim, o DW reflete sempre o estado atual de cada dimensão. A carga é idempotente, podendo ser reexecutada sem duplicar registros.

Ao final, um conjunto de consultas de verificação compara volumes entre as camadas staging, conformada e DW, confere chaves órfãs e duplicidades nas dimensões e fatos, valida as somas das medidas aditivas e checa a cobertura temporal das chaves de tempo.

6. Modelo dimensional: comentários e escolhas

O modelo foi implementado como uma constelação de fatos, isto é, um esquema dimensional com mais de uma tabela fato compartilhando dimensões conformadas. Essa escolha decorre da existência de três grãos de análise distintos no domínio.

- **fato_reserva** -- grão de uma reserva; sustenta análises de demanda, cancelamento e antecedência.
- **fato_locacao** -- grão de uma locação concluída; concentra medidas de quilometragem, quantidade de dias, atraso e cobrança.
- **fato_veiculo_no_patio** -- grão de uma movimentação de veículo entre pátios; sustenta diretamente a matriz de percentuais de movimentação e a cadeia de Markov, pois reúne eventos de transição entre pátios, e não apenas os ligados a locações.

Apesar do nome **fato_veiculo_no_patio**, seu uso analítico neste projeto representa eventos de transição entre pátios, armazenando origem, destino, veículo e data da movimentação.

As tabelas fato compartilham dimensões conformadas. A **dim_patio** é usada com papéis distintos, funcionando como role-playing dimension: retirada e devolução nas fatos de reserva e locação, e origem e destino na fato de movimentação.

A **dim_tempo** também atua em vários papéis na locação, representando datas de retirada e devolução, previstas e realizadas.

Há ainda um ramo snowflake: a **dim_veiculo** referencia **dim_grupo_veiculo** e **dim_empresa**, normalizando atributos comerciais e de propriedade. Quando necessário para simplificar consultas e filtros frequentes, as chaves de grupo e empresa também são mantidas nas fatos, sempre derivadas da dimensão de veículo durante a carga.

7. Problemas e observações gerais

- Heterogeneidade de dialetos: a diferença entre PostgreSQL, MySQL e SQL genérico exigiu cuidado na conversão de tipos, sobretudo em campos booleanos e temporais.
- Reconstrução indireta da movimentação: o caso do Grupo 2, em que o pátio de destino precisava ser recuperado por múltiplas junções, foi o ponto mais complexo e reforçou a importância da staging e da documentação das regras.

- Diferença de granularidade entre clientes e endereços: foi necessário decidir quais atributos preservar para manter um nível comum de conformação, registrando imputações quando a origem vinha incompleta.
- Atributos sem correspondência: recursos exclusivos de algumas fontes — caução, extensão de reserva, especificações detalhadas de combustível e óleo — não foram incorporados ao modelo por não terem equivalente nas demais nem relação direta com os relatórios.
- Ausência de histórico (SCD Tipo 1): como as dimensões são sobrescritas, atributos voláteis como o status do veículo refletem apenas o estado atual; o histórico de localização do veículo é capturado pela fato de movimentação, não pela dimensão.

8. Conclusão

O desenvolvimento confirmou, na prática, a justificativa para a adoção de um Data Warehouse. Diante de quatro sistemas transacionais que modelam o mesmo domínio de maneiras diferentes, somente um processo ETL bem definido permite consolidá-los em um modelo analítico coerente.

As decisões de modelagem de cada grupo fonte traduziram-se diretamente em regras de transformação, e compreender a estrutura das origens foi condição necessária para integrá-las.

A constelação de fatos resultante atende aos objetivos do projeto: entrega métricas estáveis sobre reservas, locações e movimentações, simplifica as consultas analíticas e sustenta a matriz de percentuais de movimentação entre pátios a partir de uma fato dedicada e de uma dimensão de pátio usada com papéis de origem e destino.

Conclui-se que a solução por Data Warehouse cumpre seu propósito de oferecer uma base unificada e confiável para a análise gerencial, isolando o usuário final da complexidade, das divergências estruturais e dos diferentes dialetos SQL dos sistemas de origem.