

Arquitetura de Referência — Proposta Executiva DW + Big Data

Consórcio de 6 locadoras · frota autônoma e conectada · expansão da solução DW (Parte 2) · Tarefa de Big Data (Parte 3)

Rascunho v0.2 para alinhamento do grupo · stack nomeada conforme sugestões do enunciado · sujeito a decisão final do grupo

1 EDGE · Computador de bordo

MQTT + agente embarcado

Fluxo de rotina: telemetria agregada ~1s, formato compacto (Protobuf)

Evento crítico: payload bruto imediato (colisão, pane)

Vídeo NUNCA sobe bruto — banda móvel é cara e finita

▼ rede móvel (priorização de alertas)

2 INGESTÃO · Barramento de eventos

Apache Kafka

TÓPICO TELEMETRIA.ROTINA

Alto volume, fluxo contínuo

TÓPICO ALERTAS.CRITICOS

Isolado — sem fila atrás da telemetria

Partição por vehicle_id → ordenação estrita por veículo + timestamp

Tolerância a falhas · replay · sem perda de pacote

3 PROCESSAMENTO · 3 caminhos

Spark · Flink · Hadoop/MapReduce

Hot path (emergências): Spark Streaming — alertas de pane/colisão

Análise contínua: Flink — janelas temporais, rotas, congestionamento

Batch: Hadoop/MapReduce (ou Spark) — km rodada, tempo de uso, previsão de falhas

Arquitetura Lambda vs Kappa — comparação formal no documento

Delta Lake garante ACID entre batch e streaming

4 PERSISTÊNCIA POLIGLOTA (NoSQL multi-model)

Cassandra · MongoDB · Redis

Cassandra / Astra DB (wide-column): telemetria contínua — escrita massiva distribuída

MongoDB Atlas (documentos): viagens, sinistros, inspeção de sensores

Redis (key-value em memória): cache de rotas + status da frota em tempo real

Delta Lake sobre object storage: lakehouse histórico

▼ dados conformados

5 DW & DATA MARTS — núcleo SQL (Parte 2)

PostgreSQL (estrela)

DATA CENTER DO CONSÓRCIO

Cadastros sensíveis · financeiro · cobrança (ACID)

CLOUD

Marts analíticos · histórico agregado · OLAP/BI

6 DASHBOARD & ANALYTICS

Grafana / Power BI + ML

Tempo real (via Redis/Flink): frota, viagens em andamento, emergências

Histórico (via DW): reservas, locações, cobranças, financeiro, oficina

Cobrança automática pós-devolução (km, tempo, condução, multas)

Atravessa tudo

- **Segurança & LGPD** — anonimização, sigilo
- **Orquestração** de jobs (Airflow)
- **Governança** e catálogo de dados
- **Custos cloud** — citar quando couber (exigência do enunciado)

Hot × Cold path

- **Hot:** emergência — segundos importam
- **Cold:** telemetria, histórico, relatórios
- Separação começa no **edge** e segue até o dashboard

Ambientes de estudo (free tier)

- GCP Dataproc / Flink Playground
- Databricks Free (Delta Lake)
- MongoDB Atlas · Astra DB · Redis Cloud

ML: previsão de falhas mecânicas, demanda por região

7 EXTRA · Concierge de viagem por voz

LLM + RAG + STT/TTS

Assistente IA por voz embarcado

RAG sobre base local de POIs/turismo da cidade

Integra agenda do cliente + ajusta rota no GPS

JUSTIFICATIVA-RESUMO POR CAMADA (BASE DA DEFESA ORAL)

CAMADA	POR QUE ESTA TECNOLOGIA	ALTERNATIVA DESCARTADA (E POR QUÊ)
1 · Edge	Agregação local economiza banda móvel (cara e finita); só evento crítico sobe bruto	Transmitir tudo bruto: inviável — vídeo 360° de milhares de carros saturaria a rede
2 · Kafka	Pub/Sub desacopla frota dos consumidores; partição por veículo garante ordenação estrita; replay e tolerância a falhas	REST direto ao banco: gargalo de concorrência e perda de pacotes sob pico
3 · Spark + Flink	Spark Streaming p/ alertas (hot path, ecossistema maduro); Flink p/ janelas de baixíssima latência; batch p/ consolidação histórica	Só MapReduce clássico: latência de minutos não atende emergência; Storm: comunidade em declínio
4 · Polyglot NoSQL	Cada padrão de acesso no banco certo: escrita massiva (Cassandra), semiestruturado (MongoDB), leitura sub-ms (Redis)	Um único banco para tudo: ou não escala a escrita, ou não serve o dashboard em tempo real
5 · DW SQL	Reaproveita o DW estrela da Parte 2; ACID p/ financeiro e cobrança; OLAP consolidado	Jogar tudo no lake: perderia consistência transacional do financeiro e o investimento já feito
6 · Dashboard	Grafana nativo p/ série temporal/tempo real; BI corporativo p/ visão financeira sobre o DW	Só BI tradicional: refresh em minutos não serve monitoramento de emergências
7 · Concierge (extra)	LLM com RAG sobre base local de POIs; voz via STT/TTS; ação no GPS via API do veículo	Regras fixas/menu IVR: não atende pedido em linguagem natural do exemplo do enunciado

Decisão central a defender: Lambda vs Kappa

O enunciado pede comparação formal. Caminho sugerido: **Lambda** (camadas batch + speed separadas) reflete bem os 3 tipos de processamento pedidos, mas tem duplicação de lógica; **Kappa** (tudo como stream, reprocesso via replay do Kafka) é mais simples de operar. Posição defensável: **Lambda "unificada" via lakehouse** — Delta Lake como camada única de armazenamento com garantia ACID entre batch e streaming (exatamente o exemplo citado pelo professor). O grupo precisa ratificar.

Onde roda: cloud + Data Center do consórcio

Enunciado admite os dois ("na nuvem, ou no Data Center do consórcio"). Proposta: dados sensíveis/financeiros no data center (herda o DW da Parte 2); ingestão, processamento elástico e NoSQL gerenciado na nuvem (free tiers sugeridos servem de prova de conceito). Citar custos embutidos da parte cloud — exigência explícita.

ENTREGÁVEIS (3 — ATENÇÃO AO TERCEIRO)

1 · Proposta Executiva (PDF)

Texto com pipeline completo, dashboard, justificativa de cada tecnologia (MapReduce, Spark, Flink,

2 · Slides (PDF)

Abertura com nomes+DRE · 2º slide: índice · último: conclusões. Base da defesa oral (cobre Parte 2 + Parte 3).

3 · E-mail + GitHub

E-mail a milton@matematica.ufrj.br com folha de rosto + link do repositório

Lambda/Kappa, NoSQL) + custos. Postar no AVA@UFRJ.

GitHub (docs 1 e 2 + README descrevendo a estrutura).

Regras que zeram nota

Um membro posta os PDFs; **todos os demais** postam folha de rosto no AVA (quem não postar nada fica com ZERO). Todos os arquivos com identificação completa (nomes + DRE) — sem isso não são considerados.

Rascunho v0.2 · papel do grupo: consultoria de tecnologia recomendando a stack — não implementar. Pendências para o grupo ratificar: (a) posição Lambda × Kappa; (b) Databricks vs GCP Dataproc como plataforma de processamento; (c) ferramenta do dashboard (Grafana vs Power BI vs ambos); (d) incluir ou não o extra do concierge; (e) divisão de seções entre os membros.